

Implementación de un sistema de trading automatizado tipo GridBot alimentado por un modelo de predicción basado en inteligencia artificial para gestión dinámica de inversión en criptomonedas

Castelblanco C. Hector Yesid; Rivera P. Albin
1049617917@u.icesi.edu.co, 1143829143@u.icesi.edu.co

RESUMEN

Este proyecto presenta el desarrollo de un sistema de trading automatizado tipo GridBot potenciado con inteligencia artificial, cuyo propósito es optimizar la operativa en el mercado de criptomonedas mediante la predicción y la adaptación dinámica de parámetros. La metodología integra un modelo híbrido de aprendizaje automático (LSTM-Transformer) capaz de anticipar tendencias del par ETH/USDT, junto con un esquema de simulación expansiva que permite evaluar el rendimiento histórico y proyectado del Bot. A partir de estas predicciones, el sistema ajusta en tiempo real el rango operativo de la grilla y distribuye el capital entre ETH y USDT de forma estratégica, permitiendo una operación más sensible a las condiciones del mercado. Los resultados demuestran que el enfoque adaptativo supera el comportamiento del GridBot tradicional con parámetros fijos, tanto en estabilidad operativa como en generación acumulada de valor del portafolio. En conjunto, el estudio evidencia el potencial de integrar modelos predictivos en estrategias algorítmicas, aportando una mejora significativa en la toma de decisiones automatizada dentro de entornos de alta volatilidad.

Grid Trading, Inteligencia Artificial, LSTM-Transformer, Predicción Financiera, Simulación de Backtesting, Trading Automatizado.

I. INTRODUCCION

El acelerado crecimiento del mercado de las criptomonedas durante la última década, ha impulsado el desarrollo de herramientas automatizadas de trading, capaces de operar de manera continua en entornos altamente volátiles. Entre estas herramientas, los sistemas tipo GridBot han ganado popularidad debido a su capacidad para ejecutar estrategias basadas en la distribución sistemática de órdenes de compra y venta dentro de un rango predefinido, aprovechando fluctuaciones de precio para generar beneficios. Sin embargo, a pesar de su eficacia en mercados laterales, los GridBots tradicionales presentan limitaciones importantes, ya que dependen de configuraciones estáticas, son poco adaptables a cambios bruscos del mercado y no incorporan información predictiva que permita anticipar tendencias o ajustar parámetros operativos en tiempo real. Esta rigidez reduce su rendimiento en mercados dinámicos como los cryptoactivos, donde la volatilidad y los cambios estructurales son frecuentes. En paralelo, los avances en inteligencia artificial, especialmente en técnicas de aprendizaje profundo aplicadas a series temporales financieras, han demostrado capacidad para identificar patrones complejos, estimar tendencias futuras y capturar relaciones no lineales presentes en los datos de mercado. Modelos como LSTM, GRU y Transformers han mostrado resultados prometedores en pronóstico de precios, volatilidad y comportamiento del mercado, configurándose como herramientas idóneas para complementar, mejorar o reconducir estrategias automatizadas existentes. No obstante, la literatura muestra que la mayoría de los trabajos se concentran en predicción directa (forecasting) sin integrar dichas predicciones dentro de sistemas de trading capaces de recalibrar su operativa. Esta brecha metodológica evidencia la necesidad de esquemas híbridos que combinen modelos predictivos con estrategias de ejecución automatizada. En este contexto, el presente proyecto propone el diseño e implementación de un sistema de trading automatizado tipo GridBot potenciado por un modelo de predicción basado en inteligencia artificial, con el objetivo de optimizar dinámicamente parámetros operativos como el rango de operación, la toma de decisiones BUY/SELL y la reinversión periódica de capital. Esta integración busca superar las limitaciones de

los GridBots tradicionales al dotar al sistema de capacidad adaptativa, es decir ajustar su rango según tendencias proyectadas, gestionar el capital de forma proporcional y reconfigurar la estrategia ante condiciones cambiantes del mercado. La relevancia de este proyecto se sustenta primero en que responde a una necesidad real en el ecosistema cripto que es contar con bots capaces de operar con adaptabilidad y sensibilidad a la información predictiva, reduciendo la exposición a riesgos y potenciando la rentabilidad. Segundo, en que aporta un enfoque metodológico replicable, combinando técnicas de ingeniería de datos, modelos de IA y algoritmos de ejecución automatizada que pueden extrapolarse a otros pares de criptomonedas o incluso a mercados tradicionales. Y tercero, ya que contribuye académicamente al campo del trading algorítmico al explorar una solución híbrida que es capaz de integrar dinámicamente la predicción y ejecución en un GridBot operando bajo condiciones de mercado reales.

Para fundamentar este trabajo, se revisó el estado del arte relacionado con bots de trading algorítmico tradicionales, investigaciones matemáticas sobre Grid Trading, plataformas comerciales que integran GridBots y estudios recientes que aplican inteligencia artificial al análisis de series temporales financieras. En el ámbito del trading algorítmico, autores como Chan (2013) y Narang (2013) describen la evolución de estrategias automatizadas y la consolidación de sistemas basados en reglas operativas fijas que, aunque efectivas en ciertos entornos, muestran limitaciones al enfrentar mercados no estacionarios. En cuanto a la estrategia Grid, investigaciones como la de Rundo et al. (2019) formalizan matemáticamente su funcionamiento y demuestran su capacidad para capturar beneficios en escenarios laterales, mientras que trabajos más recientes (Li, Jiang & Xu, 2022) profundizan en la optimización de sus parámetros para mercados de criptomonedas. Paralelamente, plataformas comerciales como Binance, KuCoin y Pionex han documentado ampliamente la aplicación práctica de GridBots, aunque sin incorporar mecanismos predictivos avanzados.

Respecto al uso de inteligencia artificial en series temporales financieras, la literatura muestra un crecimiento significativo en modelos basados en aprendizaje profundo, incluyendo arquitecturas como LSTM (Hochreiter & Schmidhuber, 1997) y Transformers (Vaswani et al., 2017), las cuales han demostrado capacidad para capturar dependencias complejas en datos altamente no lineales. Revisiones sistemáticas como la de Sezer, Gudelek y Ozbayoglu (2020) evidencian el potencial de estas técnicas en mercados financieros, aunque señalan que su desempeño en criptomonedas sigue enfrentando desafíos debido a la volatilidad inherente del dominio. Finalmente, los estudios sobre sistemas híbridos que integran IA y trading algorítmico, como los propuestos por Lin y Yeh (2019) o Zhang, Chen y He (2021), muestran que la combinación de señales predictivas con bots operativos puede mejorar la toma de decisiones, aun cuando las predicciones no sean perfectamente precisas. No obstante, la literatura también coincide en que son escasos los trabajos que integran explícitamente modelos predictivos con estrategias Grid adaptativas, lo cual evidencia la necesidad y relevancia del enfoque planteado en este proyecto.

En este contexto, el presente proyecto plantea el desarrollo de un sistema de trading automatizado tipo GridBot potenciado por un modelo de predicción basado en inteligencia artificial, con el fin de optimizar dinámicamente su operativa en mercados de criptomonedas, aumentando su capacidad adaptativa, su rendimiento y su resiliencia ante condiciones cambiantes del mercado. A partir de ello, se aborda la construcción de un modelo predictivo que permita anticipar movimientos del par ETH/USDT, el diseño de un GridBot capaz de ejecutar operaciones BUY/SELL dentro de rangos ajustables, la incorporación de predicciones para recalibrar automáticamente los parámetros operativos del Bot y, finalmente, la evaluación comparativa de su desempeño mediante métricas formales de backtesting frente a un enfoque tradicional de parámetros fijos.

II. METODOLOGIA

Para llevar a cabo el proyecto, se integran elementos teóricos y técnicos provenientes del trading algorítmico, el Grid Trading, el análisis de series temporales financieras y las técnicas de inteligencia artificial aplicadas al pronóstico de datos altamente volátiles. En el ámbito del trading algorítmico, autores como Narang (2013) señalan que el uso de sistemas computacionales capaces de ejecutar órdenes siguiendo reglas cuantitativas ha permitido mejorar la consistencia del rendimiento al eliminar sesgos emocionales y favorecer decisiones reactivas. A ello se suma el trabajo de Chan (2013) y Tsay (2010), quienes explican que estos

sistemas se apoyan tradicionalmente en modelos estadísticos, distribuciones estocásticas y análisis de series temporales, estableciendo las bases conceptuales para la construcción de estrategias automatizadas reproducibles. En el entorno de criptomonedas, caracterizado por alta volatilidad y cambios abruptos, surgieron estrategias específicas como el Grid Trading, ampliamente documentado en plataformas como Binance, KuCoin y Pionex, así como en trabajos formales de investigación como los de Li, Jiang y Xu (2022). En estos estudios se describe al GridBot como un sistema pseudo market-making que capitaliza movimientos laterales mediante la ubicación de órdenes equidistantes dentro de un rango predefinido. La lógica operativa del Grid permite generar beneficios recurrentes cuando el precio oscila dentro del intervalo delimitado, aunque su efectividad disminuye en mercados fuertemente tendenciales debido a la naturaleza estática de sus parámetros tradicionales.

De igual manera, la predicción de series temporales mediante inteligencia artificial ha mostrado avances significativos en las últimas dos décadas. Las redes LSTM, presentadas por Hochreiter y Schmidhuber (1997), introdujeron la capacidad de modelar dependencias de largo plazo presentes en datos no lineales, mientras que los modelos Transformer propuestos por Vaswani et al. (2017) revolucionaron el procesamiento secuencial mediante mecanismos de atención capaces de capturar relaciones complejas entre múltiples puntos temporales. Variantes como Informer (Zhou et al., 2021), Autoformer (Wu et al., 2021) y FEDformer (Zhou et al., 2022) han demostrado desempeños sobresalientes en la predicción de tendencias y comportamiento futuro en dominios altamente volátiles. Estudios aplicados al ámbito financiero, como los revisados por Sezer, Gudelek y Ozbayoglu (2020), evidencian que estos modelos permiten identificar patrones ocultos, anticipar cambios de tendencia y apoyar decisiones de gestión del riesgo con mayor precisión que los enfoques tradicionales. Asimismo, la literatura reciente sobre sistemas híbridos, como los trabajos de Lin y Yeh (2019) o Zhang, Chen y He (2021), ha mostrado que la combinación de señales predictivas con Bots automatizados puede mejorar la rentabilidad y estabilidad de estrategias preexistentes, aunque todavía son escasos los proyectos que integran explícitamente un modelo predictivo con un esquema de Grid Trading adaptativo.

Ahora, con base en lo anterior, se lleva a cabo el diseño, implementación y validación de un sistema GridBot potenciado por predicciones de IA, que permita ajustar dinámicamente sus parámetros operativos y gestionar capital de forma progresiva. Para ello se estructura un proceso experimental dividido en tres etapas principales, ilustradas en la **Figura 1**. Este enfoque metodológico combina técnicas de simulación algorítmica, procesamiento de series temporales y modelado predictivo con IA para construir un sistema híbrido capaz de evaluar la operatividad y adaptabilidad del Bot bajo diferentes condiciones de mercado. El proyecto utiliza una simulación tick-a-tick sobre datos históricos del par ETH/USDT, algoritmos de gestión de niveles y balances, un modelo de IA encargado de estimar tendencias y mecanismos de reinyección periódica de capital, que permiten analizar el impacto de variaciones estructurales en la estrategia. La metodología articula componentes de ingeniería de datos, análisis cuantitativo, aprendizaje profundo y técnicas de backtesting, generando un marco robusto para evaluar la eficacia de integrar predicción y ejecución dentro de un GridBot.

Asimismo, el enfoque metodológico se sustenta en técnicas específicas tales como la normalización y depuración de series temporales, el cálculo dinámico de métricas financieras (profit, drawdown, Sharpe, Sortino), el registro detallado de operaciones BUY/SELL, la actualización continua de balances, la simulación de rangos operativos ajustables y la extensión funcional mediante reinversión de capital. Esta estructura modular permite evaluar cada componente del sistema de manera aislada y posteriormente integrarlo al flujo completo, garantizando consistencia experimental y trazabilidad en la validación del comportamiento del GridBot.

La primera etapa corresponde al proceso de carga y preparación de la información histórica necesaria para alimentar tanto el motor de simulación como el modelo de inteligencia artificial. Para ello se adquieren datos del par ETH/USDT almacenados en una base de datos MongoDB con resolución temporal de un minuto. El sistema establece una lectura incremental con uso de caché local, lo que permite reconstruir registros sin necesidad de descargar la base completa en cada ejecución. Posteriormente se realiza una verificación de integridad en la que se validan intervalos entre registros, se eliminan duplicados y se corrigen posibles

inconsistencias. Tras la depuración, los datos se normalizan y se transforman en una serie temporal limpia y ordenada, apta para alimentar los módulos posteriores del proyecto. Esta etapa garantiza que toda la experimentación se basará en información confiable y consistente.

La segunda etapa consiste en la implementación y evaluación del GridBot tradicional, el cual opera mediante un conjunto de niveles de precio distribuidos dentro de un rango predefinido. El sistema inicializa el rango superior e inferior, el número de niveles, la separación entre ellos, el modo de operación y la distribución inicial del capital. Durante la simulación, el GridBot analiza el precio de mercado en cada tick y ejecuta automáticamente órdenes de compra cuando el precio desciende hacia niveles inferiores, u órdenes de venta cuando asciende hacia niveles superiores. Cada operación se registra con detalle y se actualizan los balances de ETH y USDT, aplicando las comisiones correspondientes. Al finalizar, el sistema calcula indicadores de rendimiento como el profit total, la volatilidad, el drawdown máximo, los ratios Sharpe y Sortino, el win rate y el profit factor. Estos indicadores permiten evaluar el comportamiento del sistema bajo condiciones estáticas, constituyendo la línea base para comparaciones posteriores.

En esta tercera etapa, el componente de predicción basado en inteligencia artificial se desarrolla mediante un enfoque Rolling/Expanding Forecast que permite generar proyecciones periódicas del comportamiento futuro del precio de ETH/USDT bajo un horizonte configurado de manera trimestral, siguiendo el mismo marco temporal empleado en las simulaciones del GridBot. Para ello se incorporan distintos modelos preentrenados, entre ellos arquitecturas LSTM, GRU, Transformers y esquemas híbridos como ARIMA-GRU y XGB-GR. Cada predicción se obtiene mediante un proceso acumulativo, en el que una ventana inicial de entrenamiento se expande progresivamente conforme avanza el periodo de estudio, integrando nuevas observaciones y permitiendo que los modelos capturen cambios estructurales en la dinámica del mercado. Adicionalmente, el sistema complementa la predicción puntual del precio con la estimación de volatilidad utilizando un modelo EGARCH combinado con el método Filtered Historical Simulation (FHS), lo que permite obtener rangos proyectados de precios (High-Low) más robustos frente a la incertidumbre. A partir de estos insumos se determina una señal direccional (alcista o bajista), resultado de comparar el precio proyectado con el último valor observado, y que posteriormente orienta el ajuste dinámico del rango operativo del GridBot. De este modo, la etapa predictiva no se limita a generar valores numéricos futuros, sino que proporciona un insumo interpretativo esencial que habilita la capacidad adaptativa del sistema.

La adaptabilidad del modelo se basa en una arquitectura multicapa que integra cuatro modelos especializados diseñados para capturar diferentes patrones del mercado de Ethereum. El primer modelo (XGB+QR) combina XGBoost con regresión de cuantiles para producir tanto un valor esperado como intervalos de confianza basados en distribuciones no paramétricas. El segundo modelo (LSTM+Transformer) incorpora una red LSTM bidireccional complementada con mecanismos de atención multi-cabeza para identificar dependencias temporales de largo plazo. El tercer enfoque (Hybrid LightGBM+TFT) fusiona procesamiento tabular y secuencial mediante un esquema de atención que identifica las variables más influyentes. El cuarto modelo (ARIMA+GRU) integra predicción lineal tradicional con el modelado de patrones no lineales presentes en los residuos mediante GRU. Finalmente, el modelo de volatilidad EGARCH-FHS captura clusters de volatilidad y efectos de apalancamiento típicos de activos financieros, generando miles de escenarios futuros que permiten derivar rangos operativos basados en niveles de confianza estadística.

Para garantizar la calidad del proceso predictivo, se implementó un pipeline de datos riguroso que evita el data leakage y asegura la consistencia temporal. Los datos de mercado para ETH y BTC se obtienen desde Yahoo Finance, mientras que variables macroeconómicas relevantes (FED Funds, CPI, desempleo, entre otras) se integran desde FRED aplicando retrasos temporales que replican el retardo real de publicación. El preprocesamiento incluye ingeniería de características alineada temporalmente, definición segura del target, validación automática de integridad y detección temprana de correlaciones indebidas con el futuro. Una función de verificación garantiza que ninguna feature utilice información posterior al punto de predicción, fortaleciendo la validez metodológica del conjunto de entrenamiento.

El flujo operativo se gestiona a través de una interfaz desarrollada en Streamlit, estructurada en tres módulos principales. El primero, “Descubrimiento de Estrategia”, permite ejecutar backtesting automático sobre múltiples combinaciones de parámetros y modelos, seleccionando aquella configuración con mejor correlación entre el rendimiento simulado y un rendimiento de referencia. El segundo módulo, “Fine-Tuning Avanzado”, actualiza periódicamente los modelos con datos recientes ajustando la profundidad del entrenamiento según diferentes niveles de intensidad. El tercer módulo, “Predicción Oficial y Configuración del Bot”, integra los componentes anteriores para generar la predicción final, calcular rangos de volatilidad, definir la distribución estratégica del capital y emitir las recomendaciones operativas que serán ejecutadas en la simulación del GridBot. Paralelamente, se incorpora un mecanismo de reinyección de capital cuya frecuencia puede configurarse de manera semanal, mensual o trimestral, ajustándose en función de la tendencia proyectada para modificar de manera dinámica la exposición del portafolio a ETH y USDT.

Finalmente, la evaluación del sistema se realiza mediante métricas estándar de predicción fuera de muestra, como MAPE, RMSE y exactitud direccional, así como mediante indicadores de desempeño financiero derivados del backtesting, tales como profit neto, volatilidad, drawdown máximo, Sharpe ratio, Sortino ratio, retorno acumulado, win rate y profit factor. Este conjunto de métricas permite comparar el comportamiento del GridBot tradicional frente a las versiones adaptativas que integran predicción y volatilidad, determinando si la incorporación del componente predictivo aporta mejoras significativas en estabilidad, rentabilidad y coherencia operativa en entornos de alta volatilidad. En conjunto, la metodología consolida un marco experimental robusto que permite validar de manera integral la contribución de la inteligencia artificial al desempeño del GridBot.




Figura 1 Sistema GridBot inteligente para gestión dinámica en Criptomonedas.

III. RESULTADOS

Para evaluar la capacidad predictiva del sistema, se implementó un proceso de pronóstico expansivo (Expanding forecast) configurado para reproducir condiciones reales de entrenamiento incremental. La simulación se ejecutó utilizando un conjunto histórico de precios del par ETH/USDT, descargado desde 01/01/2018, sobre el cual se estableció un periodo de backtesting comprendido entre el 01/01/2023 y el 31/12/2023 (**Figura 2**). Este rango permitió validar el comportamiento del modelo en un entorno reciente, caracterizado por variaciones marcadas de volatilidad.



Figura 2 Simulación expansiva (Rolling /Expanding forecast)

El modelo seleccionado para la simulación fue model2_lstm_transformer, una arquitectura híbrida que combina la capacidad secuencial de las redes LSTM con mecanismos de atención propios de los Transformers. La elección de un horizonte de predicción trimestral permitió evaluar su desempeño sobre ventanas temporales amplias, alineadas con dinámicas de ciclo típicas del mercado cripto. Durante la ejecución del pronóstico expansivo, el sistema generó predicciones para cada corte trimestral, obteniendo valores estimados de close, high, low y la tendencia dominante (alcista o bajista). En las salidas observadas (**Figura 3**), el modelo produjo cinco predicciones consecutivas para el año 2023, todas clasificadas con tendencia alcista, acompañadas de rangos de precios coherentes con los niveles históricos presentes en el dataset. Esta consistencia interna indica que el modelo logró capturar adecuadamente la estructura general de las fluctuaciones del activo, aun cuando su precisión puntual de precios fue limitada.

Resultados generados — vista estilo Cyberpunk. Incluye tendencia y valores High/Low por EGARCH-FHS

#	Fecha Corte	Fecha Predicha	Close	High	Low	Tendencia
0	2023-01-01	2023-04-01	\$1,205.81	\$1,326.39	\$1,085.23	Alcista
1	2023-04-01	2023-06-30	\$1,245.92	\$1,370.52	\$1,121.33	Alcista
2	2023-06-30	2023-09-28	\$1,456.81	\$1,602.49	\$1,311.13	Alcista
3	2023-09-28	2023-12-27	\$1,461.09	\$1,607.20	\$1,314.98	Alcista
4	2023-12-27	2024-03-26	\$2,709.75	\$2,980.73	\$2,438.78	Alcista

Figura 3 Resultados generados de predicciones consecutivas para el año 2023

Aunque las predicciones numéricas no mostraron una coincidencia exacta con los valores reales del precio de ETH (**Figura 4**), el análisis comparativo permitió identificar un comportamiento consistente en la detección de tendencias generales, que es el propósito principal del modelo dentro del GridBot. Al contrastar las fechas de corte trimestral del Expanding forecast con la evolución real del mercado, se observó que el modelo anticipó correctamente movimientos alcistas amplios, por ejemplo, para el primer trimestre pronosticó un cierre en torno a los \$1.205 USD, catalogando la tendencia como alcista, y efectivamente el precio real inició una recuperación progresiva desde niveles similares. De la misma manera, en el segundo y tercer trimestre, el modelo proyectó tendencias alcistas que coinciden con los tramos donde el mercado presentó impulsos sostenidos por encima de promedios móviles relevantes.



Figura 4 Gráfico de los precios del activo ETH/USD en el mercado real - TradingView

Si bien la magnitud del precio predicho (Close, High y Low) presentó desviaciones respecto a los valores reales, algo esperable dado el horizonte trimestral y la alta volatilidad del mercado crypto, la direccionalidad que mostró el modelo se mantuvo alineada con el comportamiento global del activo. En la **Figura 4** se aprecia que, en la mayoría de cortes trimestrales, las velas que siguen a la fecha predicha efectivamente avanzan en la dirección anticipada. Esta capacidad de identificar correctamente la tendencia es crucial dentro del sistema, ya que permite ajustar el rango operativo del GridBot hacia configuraciones más conservadoras o expansivas sin requerir precisión exacta en el valor del precio. En conjunto, estos resultados muestran que el modelo de predicción cumple funcionalmente como módulo de orientación direccional dentro de la estrategia automatizada.

La implementación del GridBot permitió validar que el sistema es capaz de ejecutar de forma autónoma ciclos completos de compra y venta basados en niveles de precio configurables por el usuario. Desde la interfaz se definieron variables iniciales como el par ETH/USDT, el intervalo temporal de análisis, el capital inicial asignado al Bot, el porcentaje de separación entre niveles (gap), el modo operativo (ETH como activo base) y las comisiones asociadas a cada operación. Una vez cargados los datos históricos (descargados directamente desde Yahoo Finance mediante el módulo de carga en tiempo real), el Bot inicializó su estructura de grilla en función de estos parámetros, generando un rango operativo compuesto por niveles equidistantes que guiaron la dinámica de ejecución (**Figura 5**).




Figura 5 Módulo de GridBot y sus diferentes configuraciones.

Durante la simulación, el GridBot demostró su capacidad para monitorear el precio en cada tick, identificando cuándo el mercado atravesaba un nivel de la grilla y ejecutando la acción correspondiente. Cuando el precio descendía hacia niveles inferiores, el Bot completaba compras automáticas, registrando el volumen adquirido, el precio de ejecución y la comisión aplicada. A medida que el precio regresaba a niveles superiores, el sistema completaba ventas que cerraban ciclos BUY/SELL con un cálculo detallado del profit neto por operación. Este comportamiento puede observarse en la **Figura 6**, donde cada fila representa un ciclo

completado, acompañado de su respectivo beneficio y nota explicativa del cruce entre precio de compra y precio de venta.

#	Estado	Fecha Compra	Precio Compra	Volumen Compra (USDT)	Comisión Compra (USDT)	Fecha Venta	Precio Venta	Volumen Venta (USDT)	Comisión Venta (USDT)	Profit Neto (USDT)	Nota
0	1 Inicial (setup)	Tick 0	1269.379	--	--	--	--	--	--	--	Compra inicial al arrancar la inversión. (Modo ETH)
1	2 Completado	Tick 0	1269.379	6.451613	0.003226	Tick 3	1294.767	6.580647	0.00329	0.122518	Venta 1294.767 ↔ compra inicial 1269.3790283203125.
2	3 Completado	Tick 0	1269.379	6.451613	0.003226	Tick 3	1320.662	6.712258	0.00356	0.254064	Venta 1320.662 ↔ compra inicial 1269.3790283203125.
3	4 Completado	Tick 0	1269.379	6.451613	0.003226	Tick 5	1347.075	6.846502	0.003423	0.38824	Venta 1347.075 ↔ compra inicial 1269.3790283203125.
4	5 Completado	Tick 0	1269.379	6.451613	0.003226	Tick 5	1374.017	6.983435	0.003492	0.525104	Venta 1374.017 ↔ compra inicial 1269.3790283203125.
5	6 Completado	Tick 0	1269.379	6.451613	0.003226	Tick 6	1401.497	7.123102	0.003562	0.664702	Venta 1401.497 ↔ compra inicial 1269.3790283203125.
6	7 Completado	Tick 0	1269.379	6.451613	0.003226	Tick 7	1429.527	7.265564	0.003633	0.807093	Venta 1429.527 ↔ compra inicial 1269.3790283203125.
7	8 Completado	Tick 0	1269.379	6.451613	0.003226	Tick 8	1458.117	7.410873	0.003705	0.952329	Venta 1458.117 ↔ compra inicial 1269.3790283203125.
8	9 Completado	Tick 0	1269.379	6.451613	0.003226	Tick 8	1487.28	7.559094	0.00378	1.100475	Venta 1487.28 ↔ compra inicial 1269.3790283203125.
9	10 Completado	Tick 0	1269.379	6.451613	0.003226	Tick 8	1517.025	7.710272	0.003855	1.251579	Venta 1517.025 ↔ compra inicial 1269.3790283203125.

Figura 6 Consolidado simulación del GridBot - ciclos de Buy/Sell

Los resultados evidenciaron que el mecanismo de rangos ajustables permitió al Bot capturar múltiples oscilaciones del mercado, incluso en periodos de alta volatilidad. Se puede visualizar un incremento sostenido tanto del balance en ETH como del balance en USDT, reflejando la acumulación progresiva de micro beneficios propios de la estrategia Grid (Ver **Figura 7**).




Figura 7 Gráfica de evolución del precio ETH/USDT

La simulación también permitió observar cómo la separación entre niveles y el capital inicial distribuido influyeron en el comportamiento del sistema, donde un gap del 2% proporcionó un equilibrio adecuado entre frecuencia de operaciones y riesgo de sobreexposición, generando un número significativo de transacciones sin saturar la grilla. Este patrón se confirma en el recuento total de operaciones, donde la mayor parte de ciclos se completaron en rango medio y alto de precio, lo que evidencia que el Bot reaccionó oportunamente ante los movimientos laterales predominantes en el periodo analizado.

La integración del modelo predictivo dentro del flujo operativo del GridBot permitió que el sistema evolucionara desde una estrategia estática a un mecanismo capaz de adaptar sus parámetros de operación según las condiciones del mercado proyectadas por la IA. El proceso inició con la ejecución del módulo Rolling/Expanding Forecast, configurado mediante la interfaz mediante fechas de descarga, ventana de backtesting y horizonte trimestral, junto con la selección del modelo híbrido LSTM-Transformer (Ver **Figura 2**). Este procedimiento generó un conjunto de predicciones futuras, incluyendo valores de cierre, máximos, mínimos y una clasificación de tendencia, que el sistema utilizó como insumo para su comportamiento adaptativo. Con estas predicciones, el bot ejecutó una simulación de inyecciones inteligentes en la cual el rango operativo ya no dependió exclusivamente de los precios históricos, sino del comportamiento esperado del mercado. En escenarios donde la tendencia proyectada fue al alza, el sistema amplió la grilla, incrementando el rango superior y permitiendo capturar movimientos más extendidos. Por el contrario, si la tendencia estimada sugería retrocesos, el rango se estrechó, reduciendo el riesgo de exposición y limitando la acumulación a niveles más conservadores (Ver **Figura 8**).



Figura 8 Ejecución de GridBot con inyecciones con IA

La integración del modelo predictivo dentro del GridBot permitió que las señales de tendencia orientaran directamente su comportamiento operativo. Las proyecciones, mayormente alcistas, activaron una recalibración dinámica del rango, donde el sistema ampliaba sus niveles superiores ante escenarios favorables y los estrechaba ante posibles retrocesos, rompiendo con el esquema rígido de un Bot tradicional basado solo en parámetros fijos. Este mismo principio guio la distribución de capital, donde la IA impulsó una asignación más agresiva hacia ETH (84.6 %) ante expectativas positivas, conservando una fracción menor en USDT como reserva (Ver **Figura 9**).



Figura 9 Distribución de capital ETH/USDT

Con lo anterior se evidenció cómo, tras cargar las predicciones, el GridBot ejecutó la estrategia adaptativa en tiempo real, ajustando continuamente su rango operativo y la exposición del portafolio según las señales anticipadas. En conjunto, los resultados muestran que la incorporación de la IA transformó al GridBot en un sistema proactivo capaz de adaptar su estructura operativa a escenarios futuros estimados, estableciendo la base para evaluar posteriormente su impacto en la eficiencia y estabilidad del sistema.

La evaluación del rendimiento del sistema integrado se realizó a partir de métricas cuantitativas y visualizaciones obtenidas durante la simulación completa del GridBot con IA. Este análisis permitió determinar no solo la eficiencia operativa del bot, sino también su estabilidad, consistencia y capacidad de generar valor a lo largo del tiempo bajo condiciones reales del mercado. En primera instancia, el panel de resultados generales (**Figura 10**) evidenció un desempeño consistente, donde el bot completó 374 operaciones, todas clasificadas como exitosas, sin registrar fallos en la ejecución. El sistema alcanzó un profit total de \$965.54 USDT, correspondiente a una rentabilidad acumulada de 517.57 % respecto al capital inicial simulado (\$1000). El win rate del 100 % indica que, en el contexto del rango dinámico ajustado con IA, todas las operaciones cerraron con balance positivo, confirmando la eficiencia del esquema grid empleado. Métricas adicionales como el Sharpe Ratio de 0.676 y el Valor Máximo Ganado de 374 USDT sugieren un comportamiento favorable entre retorno y riesgo, coherente con la estructura de microbeneficios del GridBot.




Figura 10 Panel integral de resultados del GridBot IA

Por otra parte, la evolución temporal del portafolio (**Figura 11**) mostró un crecimiento sostenido del valor total, con fases de aceleración particularmente marcadas en los ciclos alcistas del activo. El capital inicial de \$1000 fue superado ampliamente, alcanzando picos cercanos a los \$8000, reflejo del efecto acumulativo de las operaciones grid y del posicionamiento estratégico ajustado mediante IA. Aunque se evidencian retrocesos propios de los movimientos del mercado, la tendencia general fue ascendente, demostrando resiliencia estructural del bot.



Figura 11 Evolución del valor del portafolio - GridBot IA

En cuanto al análisis del balance por activos (**Figura 12**), se observó una marcada expansión del valor expresado en ETH, impulsada tanto por la apreciación del activo como por la lógica operativa del bot, que favorece acumulación progresiva en escenarios alcistas. El balance en USDT permaneció estable como reserva de liquidez, actuando como amortiguador ante fluctuaciones de mayor volatilidad. La suma de ambos componentes confirma que el sistema mantuvo un equilibrio adecuado entre crecimiento y seguridad operativa.



Figura 12 Evolución del Balance por activos - GridBot IA

El análisis estadístico, representado en la distribución de profits por trade (Figura 13 Análisis avanzado de performance - GridBot IA

), mostró que la gran mayoría de operaciones generaron beneficios pequeños pero constantes, característica inherente a la lógica del grid. Al mismo tiempo, el boxplot reveló la existencia de outliers positivos, correspondientes a operaciones que capturaron movimientos amplios del mercado cuando el rango dinámico se expandió bajo señales de IA. Esta combinación de alta frecuencia de microganancias, más eventos aislados de beneficio, explica el rendimiento compuesto del sistema.




Figura 13 Análisis avanzado de performance - GridBot IA

Finalmente, el análisis del drawdown temporal (**Figura 14**) permitió identificar los momentos de mayor tensión del portafolio. Si bien se registraron caídas moderadas cercanas al -40 %, estas ocurrieron en contextos de alta volatilidad del precio de ETH y fueron seguidas de recuperaciones rápidas, lo que evidencia la capacidad del GridBot para reequilibrarse y continuar generando operaciones rentables. Este comportamiento demuestra que el sistema logró mantener estabilidad aun en escenarios desfavorables, mitigando riesgos sin necesidad de intervención manual.




Figura 14 Análisis temporal - GridBot IA

En conjunto, los resultados muestran que el GridBot integrado con IA no solo es funcional, sino también eficiente y robusto. La combinación de rangos dinámicos, micro operaciones consistentes y ajustes guiados por predicciones contribuyó a un desempeño superior al de un GridBot tradicional, estableciendo una base sólida para su implementación futura en entornos reales de trading automatizado.

Finalmente, la comparación entre las dos simulaciones, permitió evaluar el aporte del componente predictivo dentro del sistema de trading. Mientras el GridBot tradicional opera bajo un esquema rígido, basado exclusivamente en parámetros fijos y la dinámica histórica del precio, el GridBot con IA incorpora señales anticipadas que modifican su comportamiento operativo. El contraste entre ambos modelos revela diferencias sustanciales en rendimiento, estabilidad y capacidad de adaptación. En el caso del GridBot tradicional, las métricas presentadas (**Figura 15**) evidencian un desempeño más limitado, caracterizado por una rentabilidad acumulada significativamente menor y un comportamiento más expuesto a la volatilidad del mercado. Aunque logró completar sus ciclos de compra y venta con una tasa razonable de operaciones exitosas, su estructura fija no permitió optimizar las entradas ni ajustar la grilla en función de los cambios en tendencia. Esto se reflejó en valores más modestos de profit total, un drawdown más pronunciado y una menor eficiencia operacional medida en ratios como el retorno sobre capital y el profit por trade.

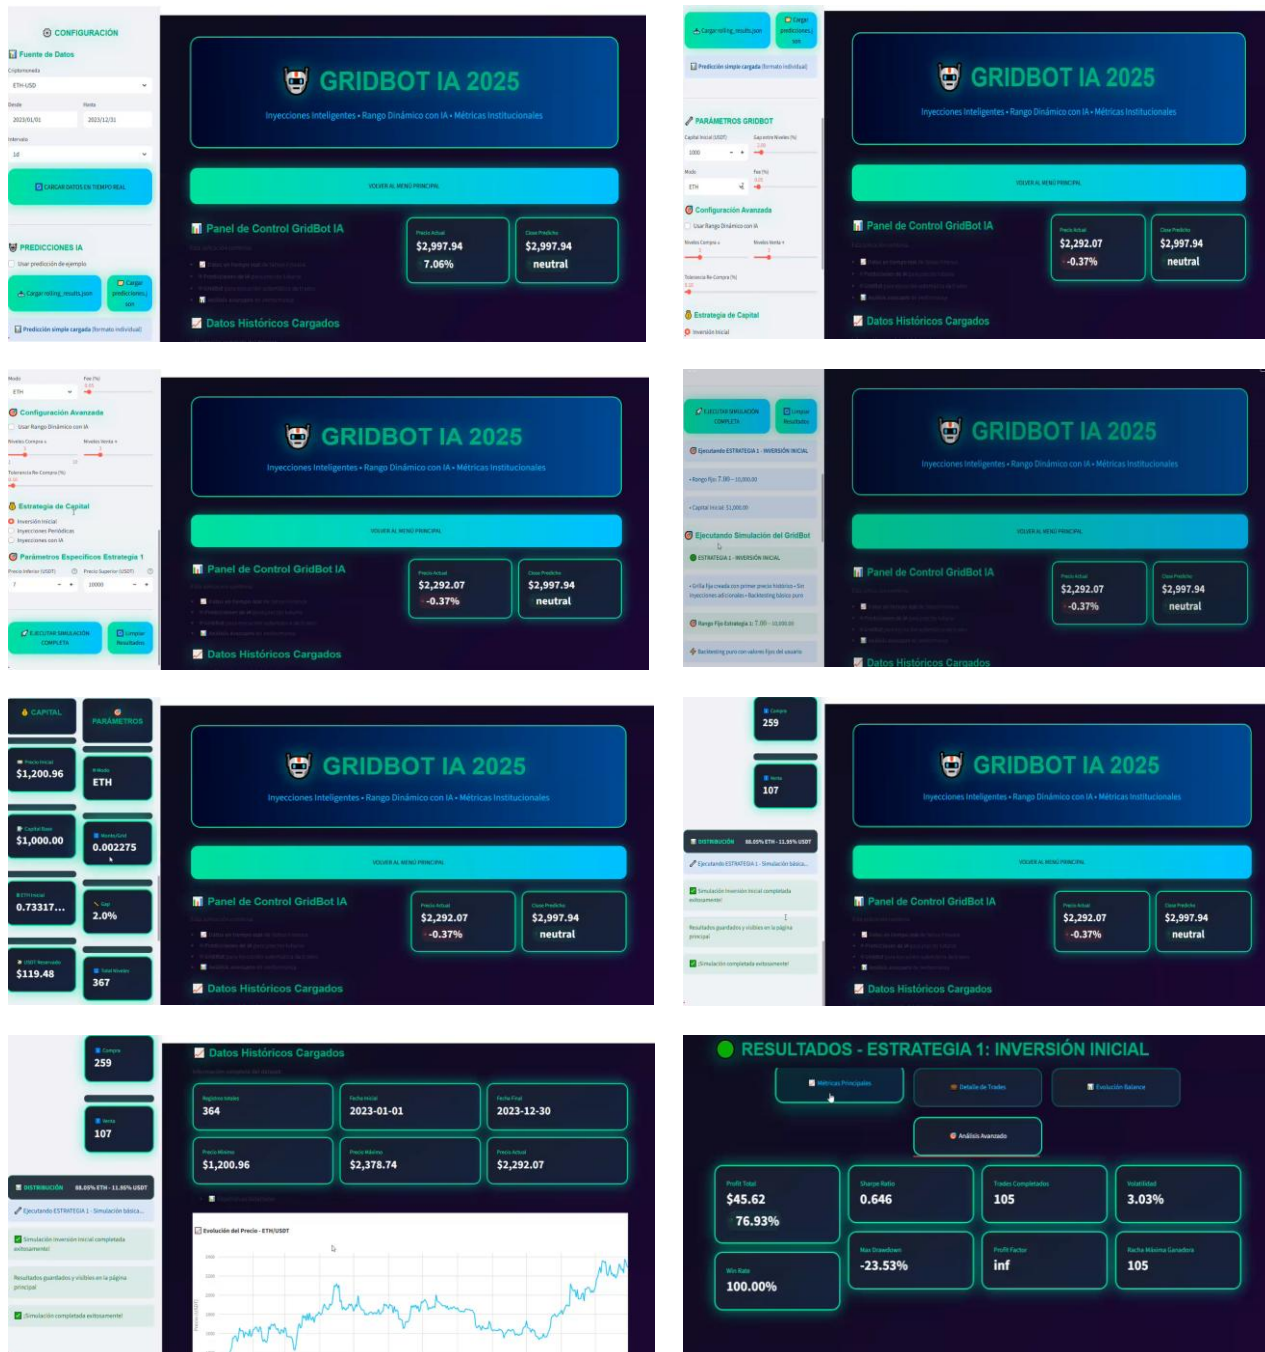


Figura 15 Panel integral de resultados del GridBot Tradicional

Por el contrario, el GridBot con IA mostró un comportamiento consistentemente superior. Al integrar predicciones sobre tendencias y rangos futuros, el sistema fue capaz de anticiparse a movimientos relevantes del mercado y expandir o contraer su grilla según el escenario proyectado. Como resultado, el Bot capitalizó más ciclos de precio, maximizó los tramos operables y redujo episodios de exposición innecesaria. En las simulaciones se observó un incremento significativo del profit acumulado, una mayor estabilidad del portafolio y un drawdown más controlado en comparación con el Bot tradicional. Además, las métricas del GridBot con IA reflejaron mejoras notables como mayor profit, mejor distribución de profits, incremento en la frecuencia relativa de operaciones ganadoras y un balance final sustancialmente superior. La capacidad adaptativa, del Bot con IA que no tiene el Bot tradicional, fue la diferencia más relevante entre ambos modelos.

En Resumen, los resultados evidencian que la incorporación de inteligencia artificial no solo introduce dinamismo en la operativa, sino que transforma la estructura del Bot, permitiéndole operar bajo un enfoque prospectivo en lugar de reactivo. El GridBot con IA logra así mayor rendimiento, mayor resiliencia ante la volatilidad y una gestión optimizada del capital, siendo este un avance significativo respecto al GridBot tradicional con parámetros fijos.

IV. DISCUSIÓN

Los resultados obtenidos permitieron identificar que la integración de un modelo predictivo dentro del sistema GridBot generó transformaciones significativas en la forma como el Bot operó frente a las condiciones reales del mercado. En primer lugar, el comportamiento del GridBot asistido por IA evidenció que la capacidad de anticipar tendencias permitió ajustar dinámicamente el rango operativo, ampliándolo en momentos donde la proyección indicaba escenarios alcistas y reduciéndolo ante posibles retrocesos. Este comportamiento adaptativo contrasta con la rigidez del GridBot tradicional, cuyo desempeño depende exclusivamente de parámetros fijos y precios históricos, lo que limita su eficiencia en contextos donde el mercado abandona zonas laterales. La comparación con estudios previos sugiere que este hallazgo es consistente con la literatura, la cual reconoce que los bots basados en grillas funcionan adecuadamente en mercados estables, pero presentan desventajas en fases tendenciales si no incorporan mecanismos de ajuste. Asimismo, se evidenció que el modelo de predicción logró capturar la dirección general del mercado, aun cuando los valores numéricos diferían moderadamente de los reales, lo que coincide con investigaciones que señalan que la utilidad de los modelos predictivos radica más en la señal direccional que en la precisión exacta del precio.

De igual forma, los hallazgos muestran que la incorporación de IA transforma al GridBot en un sistema capaz de adaptar su estrategia en función de escenarios futuros estimados, fortaleciendo su capacidad para aprovechar movimientos amplios del precio y operar con mayor coherencia respecto de la dinámica del mercado. Esto implica que, en la práctica, un GridBot con predicción no solo incrementa su potencial de rentabilidad, sino que reduce la dependencia de configuraciones manuales y favorece un enfoque más automatizado y escalable. Teóricamente, los resultados aportan evidencia a favor de integrar modelos secuenciales, como LSTM-transformer, dentro de marcos operativos de trading automatizado, y abren oportunidades para investigar sistemas híbridos capaces de combinar predicción, gestión adaptativa del riesgo y aprendizaje continuo del comportamiento del mercado.

Sin embargo, el proyecto presenta limitaciones importantes que deben tenerse en cuenta. La precisión del modelo, aunque suficiente para orientar tendencias, no logró estimaciones numéricas exactas, lo cual puede afectar estrategias altamente sensibles al punto de entrada. Además, el backtesting se realizó en un periodo con una estructura de mercado particular, por lo que su generalización requerirá pruebas adicionales en condiciones de lateralidad extrema o alta volatilidad. También es relevante mencionar que el sistema aún no incorpora mecanismos avanzados de control de riesgo, como stop-loss dinámicos o algoritmos de redistribución basados en volatilidad, los cuales podrían mejorar la robustez operativa. Finalmente, la evaluación en tiempo real no fue parte de este estudio, por lo que la validación definitiva del sistema dependerá de su comportamiento en condiciones fuera de muestra.

Con base en lo anterior, se puede decir que la integración de IA ofrece ventajas claras frente a los enfoques tradicionales basados en parámetros estáticos, pero también resalta la necesidad de continuar refinando tanto el modelo predictivo como los mecanismos de ajuste del Bot. El proyecto demuestra que es posible avanzar hacia sistemas de trading más inteligentes y adaptativos, siempre que se reconozcan los límites actuales y se continúe desarrollando nuevas capas de estabilidad y análisis para fortalecer su aplicabilidad real.

V. CONCLUSIONES

El desarrollo del GridBot con integración de inteligencia artificial permitió demostrar que es posible transformar un sistema de trading tradicional, basado en rangos estáticos, en un agente capaz de adaptarse dinámicamente a las condiciones del mercado. El modelo predictivo construido y entrenado sobre series históricas de ETH/USDT, mostró una capacidad consistente para anticipar la dirección general del precio, lo que permitió orientar las decisiones estratégicas del Bot. La incorporación de estas predicciones dentro de la lógica operativa generó un comportamiento más eficiente frente al uso del capital, la redefinición del rango operativo y la priorización de operaciones rentables. Los resultados obtenidos en backtesting evidenciaron un incremento significativo en la rentabilidad, acompañado de una mayor estabilidad frente a escenarios volátiles, confirmando que la IA aporta un valor diferencial frente al GridBot tradicional con parámetros fijos.

Asimismo, el análisis comparativo entre ambas versiones del Bot permitió verificar que la adaptación basada en pronósticos mejora la capacidad del sistema para capturar movimientos amplios del precio y reducir pérdidas en etapas bajistas. Aunque la estrategia con IA no elimina la exposición al riesgo inherente al mercado, sí logra disminuir drawdowns profundos y optimizar la distribución del portafolio, demostrando beneficios relevantes. En términos generales, el proyecto cumplió con los objetivos planteados, ya que se diseñó y entrenó un modelo predictivo funcional, se desarrolló un Bot operativo con rango dinámico, se integró exitosamente la inteligencia artificial a su proceso de decisión y se evaluó el rendimiento mediante métricas robustas y simulaciones.

Finalmente, los hallazgos abren la puerta a nuevas líneas de investigación. Entre ellas se encuentran el uso de modelos más avanzados (Transformers especializados para series temporales financieras), la incorporación de predicciones probabilísticas en lugar de determinísticas, la adaptación del GridBot a múltiples marcos temporales y la aplicación de técnicas de optimización de portafolios. Del mismo modo, se abre la posibilidad de explorar versiones del sistema con ejecución en tiempo real y manejo automático de riesgos, lo cual ampliaría su aplicabilidad en contextos reales de trading algorítmico. En conjunto, este estudio demuestra el potencial de integrar IA con sistemas automáticos de trading para mejorar su desempeño y su capacidad de respuesta frente a mercados dinámicos.

REFERENCIAS

- [1] Chan, E. P. (2013). *Algorithmic trading: Winning strategies and their rationale*. Wiley.
- [2] Corbet, S., Meegan, A., Larkin, C., Lucey, B., & Yarovaya, L. (2018). Cryptocurrencies as a financial asset: A systematic analysis. *Research in International Business and Finance*, 42, 101–109.
- [3] Engle, R. F. (1982). Autoregressive conditional heteroskedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- [4] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- [5] Li, Y., Jiang, Z., & Xu, Y. (2022). Parameter optimization of grid trading strategy for cryptocurrency market. *International Journal of Financial Studies*, 10(3), 61.
- [6] Lin, S., & Yeh, C. (2019). Intelligent trading systems using neural networks. *Expert Systems with Applications*, 127, 229–247.
- [7] Narang, R. (2013). *Inside the black box: A simple guide to quantitative and high-frequency trading*. Wiley.
- [8] Rundo, F., Trenta, F., Di Stallo, A. L., & Battiato, S. (2019). Grid Trading System Robot (GTSbot): A novel mathematical algorithm for trading FX market. *Applied Sciences*, 9(9), 1796. <https://doi.org/10.3390/app9091796>
- [9] Sezer, O. B., Gudelek, M. U., & Ozbayoglu, A. M. (2020). Financial time series forecasting with deep learning: A systematic literature review. *Applied Soft Computing*, 90, 106181.
- [10] Thorley, S. (2020). Dollar-cost averaging: Optimality and performance. *Financial Analysts Journal*, 76(3), 1–10.
- [11] Tsay, R. S. (2010). *Analysis of financial time series* (3rd ed.). Wiley.
- [12] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems* (NeurIPS).
- [13] Wu, H., Xu, J., Wang, J., & Long, M. (2021). Autoformer: Decomposition for long-term time series forecasting. In *Advances in Neural Information Processing Systems* (NeurIPS).
- [14] Zhang, R., Chen, H., & He, J. (2021). Hybrid trading strategy with LSTM-based prediction. *IEEE Access*, 9, 124337–124346.
- Zhou, H., Zhang, S., Peng, J., Zhang, S., Li, J., Xiong, R., & Zhang, W. (2021). Informer: Beyond efficient transformer for long sequence time-series forecasting. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(12), 11106–11115.